

Snorkel: Rapid Training Data Creation with Weak Supervision

Ratner et al. — Stanford University (2017)

Ramiro Sanes y Joaquín Guerra

1. Resumen

Snorkel es un sistema que permite entrenar modelos de machine learning sin etiquetar datos a mano. En lugar de anotar ejemplos uno por uno, los usuarios (expertos) escriben Labeling Functions (LFs): funciones Python que expresan heurísticas y conocimiento de dominio para etiquetar datos automáticamente. El sistema tiene en tres etapas: (1) las LFs generan una matriz de votos ruidosos; (2) un modelo generativo aprende la precisión y correlaciones de cada LF sin ground truth, produciendo etiquetas probabilísticas $\hat{y}$; y (3) un modelo discriminativo se entrena sobre esas etiquetas y generaliza más allá de las LFs, cubriendo el 100% de los datos nuevos.

La demo aplica este pipeline a ~30.000 reviews de productos para clasificar sentimiento en Negativo / Neutro / Positivo. Sin etiquetar ningún ejemplo a mano, el modelo clasifica correctamente el 59.7% de los casos que ninguna LF cubría — demostrando generalización real.

2. Por qué elegimos este artículo

Elegimos Snorkel porque ataca el problema central de ML en producción: el etiquetado de datos es el cuello de botella real, no la arquitectura del modelo. El paper no es solo una propuesta teórica — fue desplegado en producción real con el Departamento de Veteranos de EE.UU., la FDA y Stanford Hospital, lo que lo convierte en un caso de estudio directamente relevante para la materia.

3. Aplicaciones e implicancias para ML en Producción

El paper valida Snorkel en seis dominios: registros médicos (VA + Stanford), literatura científica (FDA + PubMed), relaciones bioquímicas (CDR), radiografías (cross-modal: LFs sobre texto → modelo sobre imagen), detección de relaciones en noticias, y análisis de sentimiento en crowdsourcing.

Las implicancias para producción son claras. Cuando cambian los requisitos del proyecto, se reescriben LFs en lugar de re-etiquetar miles de ejemplos. El conocimiento de dominio queda explícito en código versionable y auditable. El sistema escala automáticamente con más datos sin etiquetar, y es agnóstico al modelo downstream: las etiquetas generadas funcionan con LogReg, LSTM, ResNet o BERT según el problema. El caso cross-modal (LFs en texto, modelo en imagen) abre posibilidades especialmente valiosas cuando los datos de un dominio son abundantes y los de otro son escasos.

4. Aprendizajes y conclusiones

El aprendizaje central es que el modelo generativo de Snorkel estima la precisión de las LFs observando únicamente sus acuerdos y desacuerdos, sin necesitar ninguna etiqueta real. En nuestra demo, el Label Model no superó al Majority Vote — comportamiento consistente con la teoría del paper: con pocas LFs y alta superposición entre ellas, la densidad de señal es insuficiente para el modelo generativo.

La conclusión principal es que Snorkel desplaza el cuello de botella: de “conseguir etiquetas” a “codificar conocimiento de dominio”. Esto es un cambio de paradigma relevante para cualquier equipo que trabaje con datos sin etiquetar a escala. La limitación honesta es que la calidad del pipeline depende de qué tan bien el experto puede articular las heurísticas del dominio en código: si el dominio es demasiado sutil para reglas explícitas, la cobertura de las LFs será baja y el discriminativo verá pocos ejemplos.

5. Demo técnica

La demo implementa el pipeline completo de Snorkel sobre ~30.000 reviews de productos. Se escribieron 13 LFs en Python (keywords, negaciones y patrones de estructura) para clasificar sentimiento en tres clases sin etiquetar datos a mano. El modelo discriminativo (TF-IDF + Logistic Regression) alcanzó el 77% del F1 del clasificador supervisado con labels reales, y clasificó correctamente el 59.7% de los ejemplos que ninguna LF cubría. El notebook está completamente ejecutado con todos los outputs y gráficos visibles.

Código: [Repositorio](#) (notebook .ipynb + dataset CSV)
