

Snorkel

Rapid Training Data Creation with Weak Supervision

Autores originales: Ratner, Bach, Ehrenberg, Fries, Wu, Ré — Stanford University (2017)

Ramiro Sanes y Joaquín Guerra — Machine Learning en Producción, 2026

MOTIVACIÓN

“Labeling training data is increasingly the largest bottleneck in deploying machine learning systems.”

- Etiquetar datos es caro y lento
- Requiere expertos de dominio
- Si cambia la definición del problema, hay que re-etiquetar
- Deep Learning necesita grandes volúmenes de datos etiquetados

SOLUCIÓN: ARQUITECTURA SNORKEL

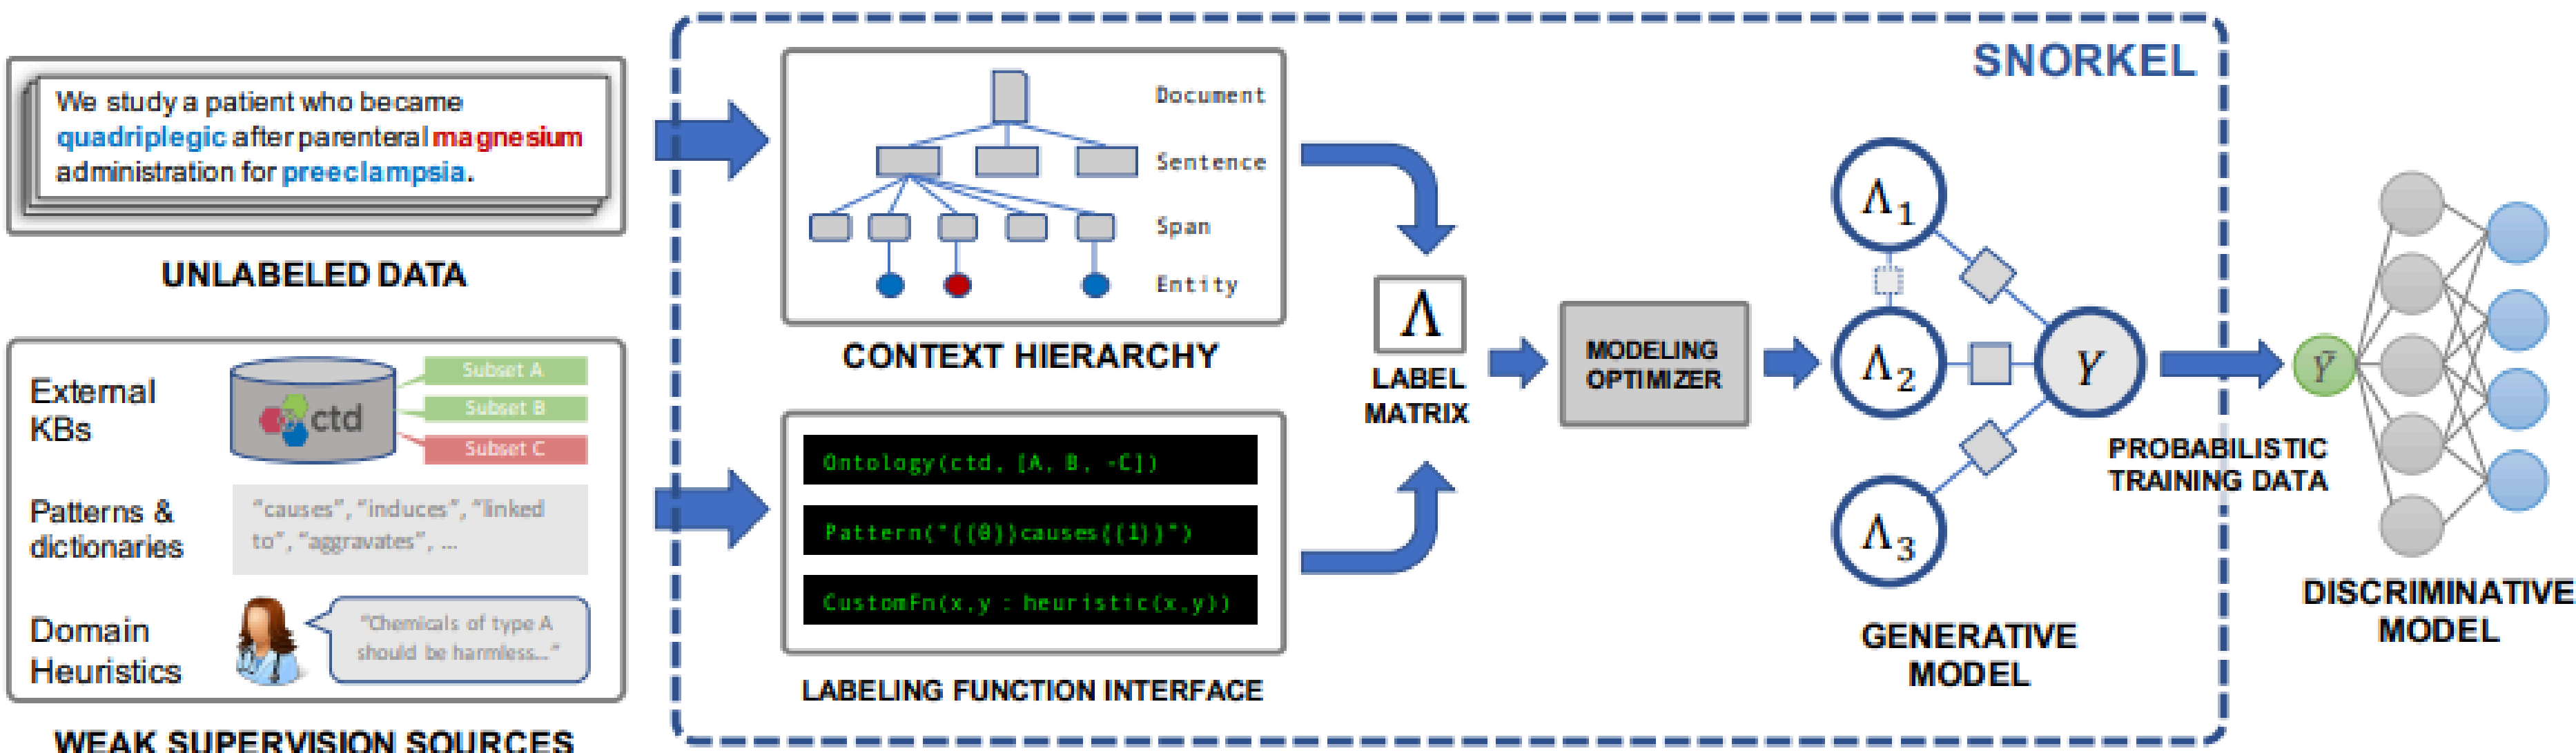


Figura 2 (Ratner et al., 2017): Pipeline de Snorkel. Las LFs etiquetan datos débilmente → el modelo generativo estima precisiones y produce $\hat{y}$ → el modelo discriminativo generaliza.

1. **Escribimos reglas (LFs):** Regex, heurísticas, APIs, knowledge bases, outputs de modelos.
2. **Snorkel aprende qué reglas confiar:** Estima accuracy + correlaciones sin ground truth.
3. **Genera labels probabilísticos**
4. **Entrena cualquier modelo final:** BERT, XGBoost, CNN, etc.

EJEMPLO ECOMMERCE

LABELING FUNCTIONS (LFS)	MODELO GENERATIVO	DISCRIMINATIVO
Producto: Pan de arroz sin TACC orgánico LF1: contiene “sin TACC” → Gluten Free LF2: contiene “orgánico” → Organic LF3: categoría panificados → Bakery	Snorkel combina señales de las LFs: Gluten Free = 0.96 Organic = 0.88 Bakery = 0.91	Entrena el modelo final

RESULTADOS CLAVE

- **2.8x** más rápido que etiquetado manual
- **+45.5%** performance vs etiquetado manual
- **+132%** vs distant supervision
- **A solo -3.6%** de datasets etiquetados manualmente

APLICACIONES REALES

- 🏥 **Salud** — extracción de información clínica en notas médicas - clasificar imágenes de radiología usando reportes de texto
- 🔬 **Ciencia** — relaciones químico-reacción en papers
- 📰 **Noticias** — relaciones entre personas en noticias

IMPLICANCIAS PARA ML EN PRODUCCIÓN

- **Velocidad:** Iterar reglas > re-etiquetar miles de ejemplos.
- **Escala:** Más datos sin labeling manual.
- **Expertise:** El experto aporta conocimiento, no horas de tagging.
- **Flexibilidad:** Funciona con cualquier modelo downstream.
- **Mejora continua:** Nuevas reglas → nuevo dataset → nuevo modelo.

CONCLUSIONES

Snorkel mueve el foco de “anotar datos” a “programar conocimiento experto”.
Eso acelera el desarrollo de sistemas de ML reales y escalables.